

TP Final

Análisis de Series de Tiempo

Juan Pablo Alianak

Tabla de contenido

1. Introducción.....	3
2. Pregunta de investigación.....	3
3. Descripción de los datos	3
3.1 Origen	3
3.2 Características generales	3
3.3 Limpieza	4
3.4 Atributos principales	4
4. Análisis de la serie	4
5. Modelos	6
5.1 Holt-Winters	6
5.1.1 Suavizado Exponencial Simple	6
5.1.2 Suavizado Exponencial Doble	7
5.1.3 Suavizado Exponencial Triple	9
5.2 ARIMA	11
5.2.1 Función de Autocorrelación Parcial	12
5.2.2 Función de Autocorrelación	12
5.2.3 Dickey-Fuller	13
5.2.4 Modelos	14
5.3 SARIMA.....	17
5.4 RNN-LSTM	20
6. Conclusiones	22

1. Introducción

El presente informe tiene como objetivo analizar una serie de tiempo correspondiente a las temperaturas máximas diarias registradas en la ciudad de Melbourne. Este tipo de variable climática representa un fenómeno continuo en el tiempo.

Mediante técnicas de modelado de series de tiempo, se busca identificar patrones estructurales en los datos, tales como tendencia, estacionalidad y ruido, y evaluar la capacidad predictiva de distintos enfoques estadísticos. Para ello, se implementaron modelos representativos que permiten comparar el desempeño de cada uno en función de métricas cuantitativas de error y visualización de resultados. El análisis se realiza sobre datos históricos, y contempla una fase de limpieza, exploración, modelado y validación.

A continuación, se expone la pregunta de investigación, junto con una descripción detallada de los datos utilizados, la metodología aplicada y los resultados obtenidos.

2. Pregunta de investigación

¿Es posible predecir la temperatura máxima diaria de la ciudad analizada mediante modelos de series de tiempo?

El objetivo de este trabajo es evaluar la capacidad de distintos enfoques de modelado para generar pronósticos a corto plazo, que puedan resultar útiles para análisis climáticos o planificación local.

3. Descripción de los datos

3.1 Origen

Los datos utilizados en este análisis fueron obtenidos de la carpeta <https://github.com/jbrownlee/Datasets/daily-max-temperatures.csv> proporcionada por la catedra.

El conjunto de datos incluye registros históricos de temperatura máxima diarias en la ciudad de Melbourne.

3.2 Características generales

- **Periodo cubierto:** 01/01/1981 al 31/12/1990
- **Frecuencia:** Diaria
- **Cantidad de observaciones:** 3650

3.3 Limpieza

Para asegurar la calidad del análisis, se inspeccionó la serie temporal en busca de valores faltantes mediante la detección de valores NaN en la columna de temperaturas. Esto permitió identificar dos fechas con datos ausentes. A fin de conservar la continuidad y coherencia de la serie, dichos valores fueron completados mediante interpolación lineal, utilizando los registros de temperatura inmediatamente anteriores y posteriores como referencia.

3.4 Atributos principales

Atributo	Tipo de dato	Descripción
Date	Object	Fecha del registro
Temperature	Float64	Temperatura máxima del día, en grados Celsius

4. Análisis de la serie

En la figura 1 se observa la serie completa donde claramente se visualiza un comportamiento estacional anual. Las temperaturas máximas se dan en los meses de verano mientras que las mínimas se dan en los de invierno. Este comportamiento se repite como un patrón durante los 10 años de la serie. También se observa un leve decaimiento de las temperaturas máximas registrados en cada año. En la figura 2 se observa la misma serie durante el último año. Aquí también vemos el comportamiento periódico de la serie, con variaciones de amplitud de relativa importancia a lo largo de los días. Este comportamiento podría ser atribuible a condiciones atmosféricas de las cuales no se disponen datos.




Fig:1 Grafica de la serie de tiempo completa




Fig:2 Grafica de la serie de tiempo último año

En la Figura 3 se muestra la descomposición aditiva de la serie de temperaturas máximas. En el componente de tendencia no se identifica una evolución clara, lo que sugiere la ausencia de una tendencia creciente o decreciente sostenida a lo largo del período analizado. El componente estacional revela un patrón anual bien definido, que oscila de manera regular en torno a una media. El componente residual presenta una variabilidad considerable, lo que indica la presencia de fluctuaciones no explicadas por la estacionalidad ni la tendencia. Esta variabilidad puede asociarse a eventos climáticos.




Fig:3 descomposición de la serie

5. Modelos

El análisis se desarrolló en varias etapas aplicando distintos enfoques de modelado con el objetivo de encontrar el que mejor se ajuste al comportamiento de la serie de temperatura. Se evaluaron modelos de suavizado exponencial (SES, DES y Holt-Winters), así como modelos basados en series temporales lineales (ARIMA y SARIMA) y uno basado en redes neuronales (LSTM). En cada caso se valoraron la capacidad de captura de patrones, el ajuste a la serie y los errores de predicción.

5.1 Holt-Winters

Se aplicaron las tres variantes del suavizado exponencial para evaluar su desempeño sobre la serie de temperaturas máximas.

5.1.1 Suavizado Exponencial Simple

En la figura 4 se muestra el ajuste del modelo SES y el pronóstico para los últimos 30 días. El modelo ajusta bien los datos históricos, capturando correctamente la tendencia y la estacionalidad. Sin embargo, el pronóstico en este modelo es lineal y no refleja las oscilaciones diarias de la temperatura. En la siguiente tabla se observan los errores entre el pronóstico y la serie real.




Fig:4 SES de la serie con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
SES	4.804388	48.485323	6.963140	0

5.1.2 Suavizado Exponencial Doble

En la figura 5 se muestra el ajuste del modelo DES con tendencia aditiva y el pronóstico para los últimos 30 días. Tiene una característica similar al modelo simple, aunque si vemos en la tabla de errores que los de este modelo son algo menores. El orden de la tabla de ahora en adelante es de menor a mayor por la columna RMSE.




Fig:5 DES aditiva de la serie con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
DES trend add	4.683962	45.740642	6.763183	0
SES	4.804388	48.485323	6.963140	0

En la figura 6 se muestra el ajuste del modelo DES con tendencia multiplicativa y el pronóstico para los últimos 30 días. Se observa una leve pendiente hacia abajo, aunque es incapaz, al igual que el modelo con tendencia aditiva, de capturar las oscilaciones de la serie. Incluso los errores son más grandes que en los otros 2 modelos.

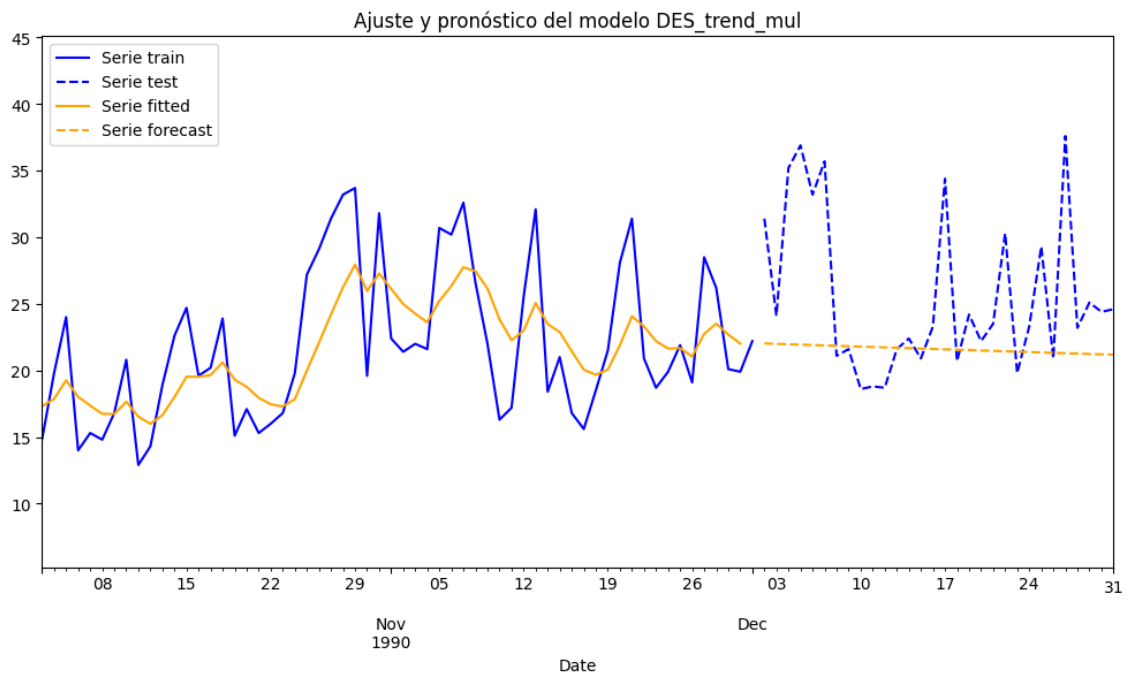


Fig:6 DES multiplicativa de la serie con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
DES trend add	4.683962	45.740642	6.763183	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0

5.1.3 Suavizado Exponencial Triple

En la Figura 7 se muestra el ajuste del modelo TES con tendencia y estacionalidad aditiva, junto con el pronóstico para los últimos 30 días. En este caso, el modelo comienza a capturar las oscilaciones en el pronóstico gracias a la incorporación explícita de una componente estacional. Es importante destacar que, aunque logra representar dichas oscilaciones, los errores resultan levemente mayores que los del modelo DES aditivo.

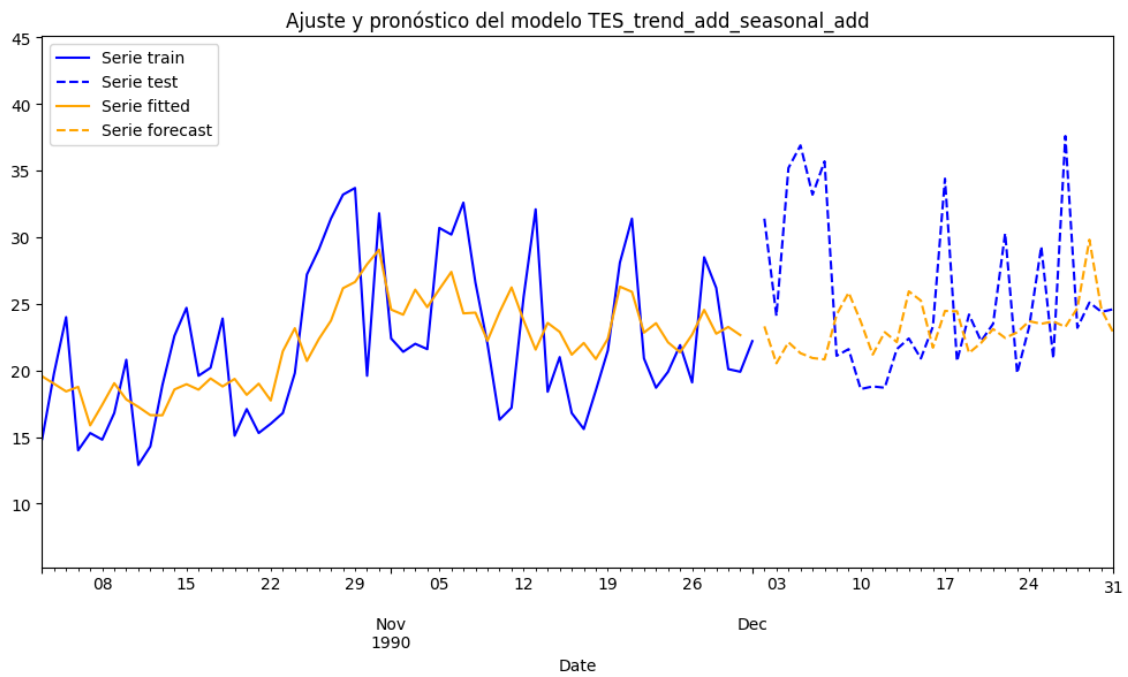


Fig:7 TES aditivo-aditivo de la serie con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
DES trend add	4.683962	45.740642	6.763183	0
DES trend add seasonal add	5.197241	48.068017	6.933110	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0

En la figura 8 se muestra el ajuste del modelo TES con tendencia y estacionalidad multiplicativa y el pronóstico para los últimos 30 días. Al igual que el modelo anterior (TES aditivo) este comienza a capturar oscilaciones, pero en este caso los errores son los mayores de todos los modelos de Holt Winters.




Fig:8 TES multiplicativo-multiplicativo de la serie con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
DES trend add	4.683962	45.740642	6.763183	0
TES trend add seasonal add	5.197241	48.068017	6.933110	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0
TES trend mul seasonal mul	5.177283	49.981925	7.069790	0

5.2 ARIMA

Los modelos ARIMA (AutoRegressive Integrated Moving Average) combinan componentes autorregresivos (AR), de integración (I) y de media móvil (MA) para modelar series temporales. Si bien no están diseñados para capturar estacionalidades explícitas, pueden ser útiles como modelo base para identificar la estructura no estacional de una serie. En esta etapa, se evaluó la aplicación de un modelo ARIMA clásico sobre la serie de temperaturas máximas diarias, con el objetivo de analizar su capacidad de ajuste y pronóstico en ausencia de componentes estacionales explícitos. Los resultados obtenidos motivaron, posteriormente, la incorporación de la estacionalidad mediante modelos SARIMA.

5.2.1 Función de Autocorrelación Parcial

En la Figura 9 se presenta la Función de Autocorrelación Parcial (PACF), la cual permite identificar la relación directa entre un valor y sus rezagos, eliminando la influencia de los rezagos intermedios. En este caso, se observa una fuerte correlación en el primer rezago, que decae rápidamente a partir de allí. Se identifican rezagos estadísticamente significativos hasta aproximadamente el rezago 10, lo que indica que los valores pasados influyen directamente en la serie, aunque esta influencia disminuye con el tiempo. Este comportamiento es útil para determinar el orden del componente autorregresivo (AR) del modelo.




Fig:9 función de autocorrelación parcial de la serie.

5.2.2 Función de Autocorrelación

En la Figura 10 se muestra la Función de Autocorrelación (ACF), la cual refleja la relación entre los valores actuales de la serie y sus valores pasados en diferentes rezagos. Se observa una caída lenta y la persistencia de valores significativos incluso en rezagos elevados, lo que indica una fuerte dependencia temporal. Además, la presencia de correlaciones significativas en múltiplos del ciclo estacional sugiere un patrón periódico en la serie. Este comportamiento es característico de series con estacionalidad, como la temperatura diaria, y resalta la necesidad de incorporar un componente estacional en el modelo para capturar adecuadamente estas dinámicas.

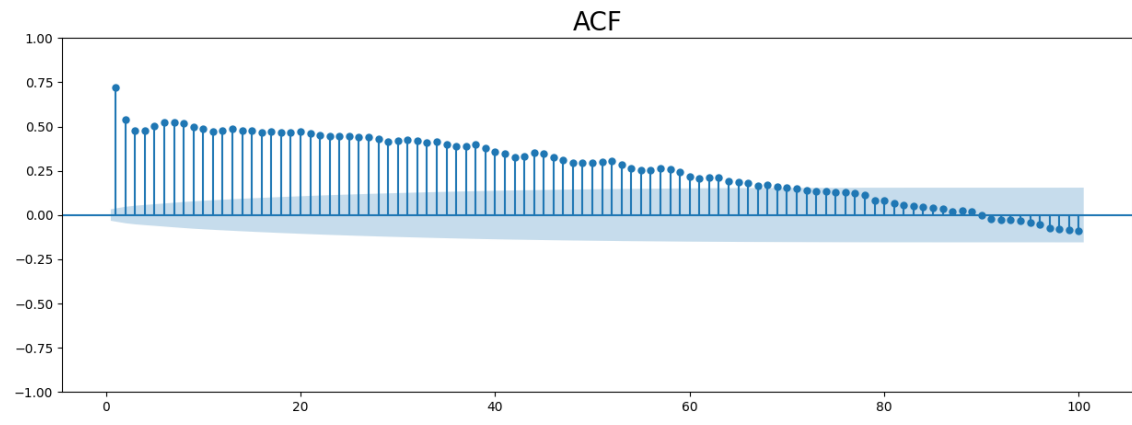


Fig:10 función de autocorrelación de la serie con 100 rezagos.

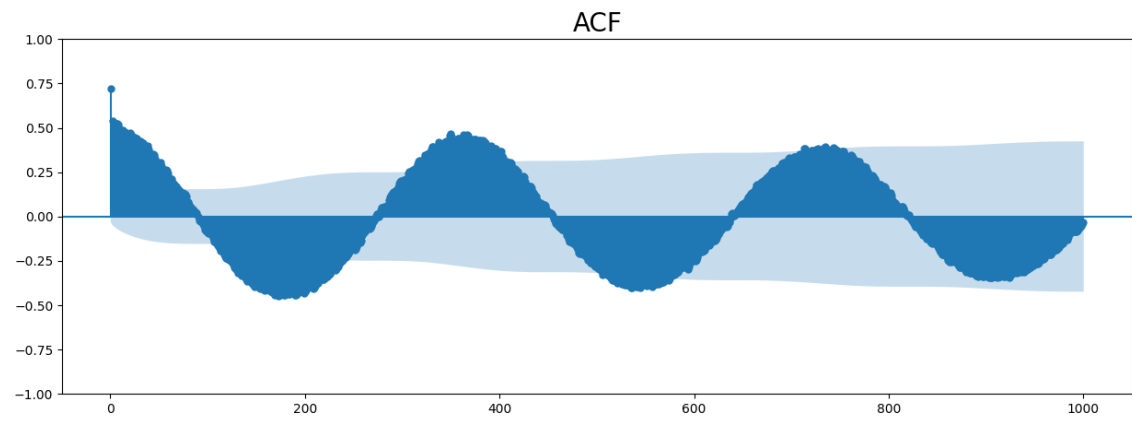


Fig:11 función de autocorrelación de la serie completa.

5.2.3 Dickey-Fuller

Para determinar si la serie es estacionaria y si es necesario incluir diferenciación en el modelo ARIMA, se realizó el test de Dickey-Fuller. En la Figura 11 se presentan los resultados del test, donde se observa que el p-valor es inferior a 0.05, lo que permite rechazar la hipótesis nula de que la serie no es estacionaria.

```
sts.adfuller(df_temperature['Temperature'])  
✓ 0.2s  
  
(-4.615638689110393,  
 0.00012086261924479347,  
 19,  
 3632,  
 {'1%': -3.4321517422129952,  
  '5%': -2.8623361092467525,  
  '10%': -2.567193781223316},  
 20166.061170099576)
```

Fig:11 resultado del test de Dickey-Fuller.

5.2.4 Modelos

Tras evaluar múltiples combinaciones de parámetros para el modelo ARIMA, se identificaron configuraciones con valores del criterio de información de Akaike (AIC) más bajos en comparación con otras alternativas. Sin embargo, muchas de estas configuraciones presentaban coeficientes no significativos según los resultados del resumen estadístico (summary) del modelo.

En este contexto, se seleccionó el modelo ARIMA(4,0,1), que, si bien no posee el AIC más bajo entre las alternativas evaluadas, ofrece un balance adecuado entre la calidad del ajuste, la significancia estadística de sus componentes y el principio de parsimonia, al evitar una complejidad innecesaria en la estructura del modelo. En la figura 12 se muestra el ajuste del modelo y el pronóstico para los últimos 30 días. Todos los coeficientes del modelo resultaron estadísticamente significativos, según los valores p informados en el *summary* (figura 13), lo que respalda su elección como modelo final. A su vez, el valor de Prob(Q) es mayor a 0.05, lo que indica que no hay evidencia de autocorrelación de los residuos, lo cual es deseable. A continuación, se presentan los resultados gráficos correspondientes a esta configuración.

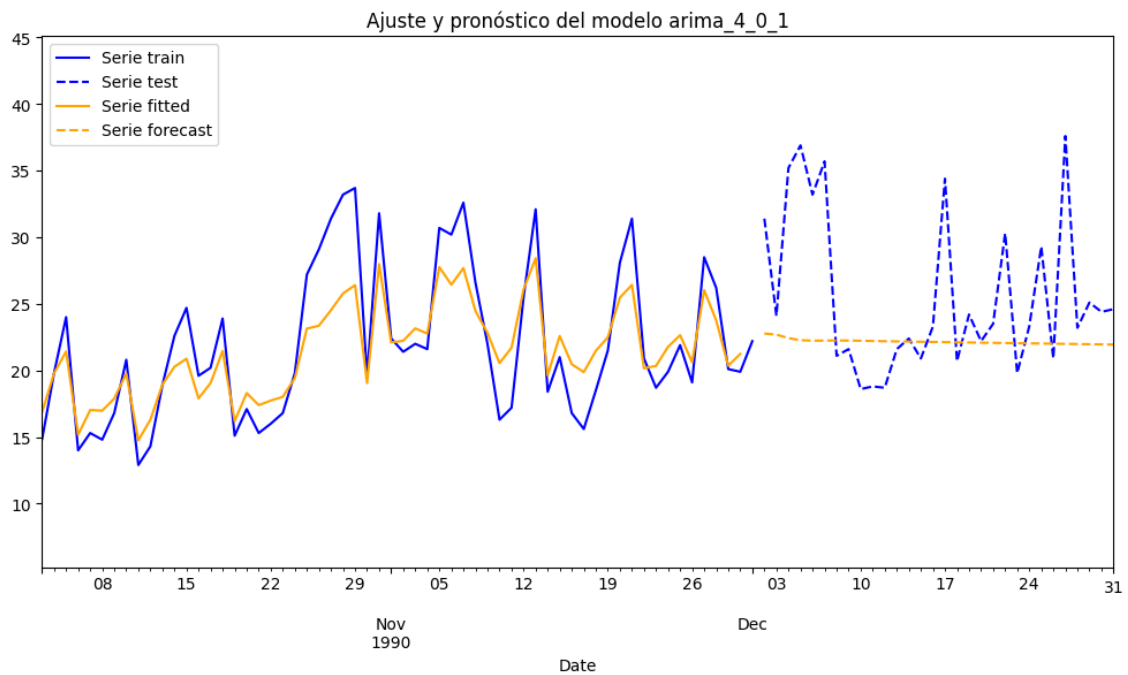


Fig:12 ARIMA(4,0,1) de la serie con el pronóstico de 30 días.

SARIMAX Results						
=====						
Dep. Variable:	Temperature	No. Observations:	3622			
Model:	ARIMA(4, 0, 1)	Log Likelihood	-10077.171			
Date:	Wed, 23 Apr 2025	AIC	20168.342			
Time:	00:03:00	BIC	20211.706			
Sample:	01-01-1981	HQIC	20183.791			
	- 12-01-1990					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	20.3690	1.525	13.360	0.000	17.381	23.357
ar.L1	1.4507	0.018	82.340	0.000	1.416	1.485
ar.L2	-0.6024	0.025	-23.730	0.000	-0.652	-0.553
ar.L3	0.0879	0.023	3.750	0.000	0.042	0.134
ar.L4	0.0581	0.015	3.921	0.000	0.029	0.087
ma.L1	-0.8899	0.011	-77.530	0.000	-0.912	-0.867
sigma2	15.2730	0.310	49.252	0.000	14.665	15.881
=====						
Ljung-Box (L1) (Q):	0.03	Jarque-Bera (JB):	399.05			
Prob(Q):	0.85	Prob(JB):	0.00			
Heteroskedasticity (H):	0.81	Skew:	0.47			
Prob(H) (two-sided):	0.00	Kurtosis:	4.33			
=====						

Fig:13 Summary del modelo ARIMA(4,0,1).

Modelo	MAE	MSE	RMSE	AIC
arima_4_0_2	4.637731	44.650831	6.682128	20177.365070
arima_4_0_4	4.649368	44.737235	6.688590	20169.256536
arima_9_0_1	4.665373	45.056665	6.712426	20172.949239
arima_4_0_1	4.665003	45.094895	6.715273	20168.342272
arima_3_0_1	4.672088	45.174594	6.721205	20176.873892
arima_5_0_1	4.672715	45.199095	6.723027	20167.102862
arima_6_0_1	4.676129	45.242637	6.726265	20169.003774
DES trend add	4.683962	45.740642	6.763183	0
TES trend add seasonal add	5.197241	48.068017	6.933110	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0
arima_10_0_0	4.902778	49.214503	7.015305	20231.295250
arima_9_0_0	4.902873	49.280944	7.020039	20247.687644
arima_8_0_0	4.917738	49.596678	7.042491	20256.629719
TES trend mul seasonal mul	5.177283	49.981925	7.069790	0
arima_5_0_0	5.205321	54.500028	7.382413	20412.400308
arima_2_0_0	5.673183	61.302760	7.829608	20684.713307
arima_1_0_0	5.679291	61.434793	7.838035	20688.210566

Si bien el modelo ARIMA(4,0,1) muestra un buen ajuste sobre la serie histórica y todos sus coeficientes son estadísticamente significativos, el pronóstico resultante no logra capturar adecuadamente las oscilaciones presentes en los datos. El comportamiento suavizado del pronóstico sugiere que el modelo tiende a representar únicamente la tendencia general, sin reflejar las fluctuaciones periódicas propias de la serie. Es un comportamiento similar a los modelos SES y DES descriptos anteriormente.

Esta limitación podría atribuirse a la presencia de una estacionalidad que no ha sido modelada y que requiere enfoques adicionales, como modelos estacionales (SARIMA).

5.3 SARIMA

Dado que el modelo ARIMA(4,0,1) no logra capturar adecuadamente las oscilaciones presentes en la serie, se exploró la incorporación explícita de la componente estacional mediante modelos SARIMA. Para ello, se conservaron los parámetros autorregresivo y de media móvil del modelo ARIMA original, y se añadieron componentes estacionales evaluando distintos periodos estacionales: 7, 15, 30, 45 y 60.

Se observó que, al incrementar el valor del período estacional, el modelo mejoraba su capacidad para representar las variaciones periódicas de la serie, tanto en los criterios de información AIC como en la capacidad de capturar las oscilaciones en el pronóstico. Esta mejora justificó la incorporación de una diferenciación estacional ($D=1$), incluso cuando el test de Dickey-Fuller no indicaba la necesidad de diferenciar la serie original. Una posible explicación de este comportamiento es que, si bien la serie presenta estacionariedad en términos generales, existen leves inconsistencias o desfases entre los ciclos anuales producto de variaciones climáticas interanuales que el modelo logra ajustar mejor al aplicar una diferenciación estacional. En este sentido, la diferenciación permite capturar mejor las fluctuaciones periódicas no perfectamente repetitivas, mejorando el desempeño general del modelo.

Se probaron ambos enfoques, utilizando tanto $D=0$ como $D=1$, y se compararon los resultados en cuanto a criterios de ajuste y rendimiento global. A pesar de que un coeficiente del componente estacional no resultó ser estadísticamente significativo en el modelo con $D=1$, este modelo mostró un mejor desempeño en términos de AIC en comparación con los modelos con $D=0$. Por lo tanto, se prefirió el modelo con $D=1$ debido a su capacidad superior para capturar la dinámica estacional de la serie, priorizando los criterios de ajuste sobre la significancia de los coeficientes individuales.

Debido a limitaciones de recursos computacionales, no fue posible evaluar configuraciones con períodos estacionales superiores a 60, lo cual podría haber sido un camino alternativo interesante. Entre los modelos evaluados, el SARIMA(4,0,1)(1,1,1)[60] presentó los mejores resultados en cuanto a los criterios de información AIC. Este modelo demostró un buen equilibrio entre complejidad y ajuste, lo que lo convierte en una opción adecuada para modelar la estacionalidad de la serie.

Por otro lado, el modelo SARIMA(4,0,1)(1,1,1)[45] fue el que obtuvo el mejor rendimiento en términos de error de pronóstico (RMSE), lo que indica que tiene una mayor capacidad para hacer predicciones precisas sobre las temperaturas futuras. Aunque su AIC no fue el más bajo, su desempeño en la predicción lo hace más adecuado para el objetivo principal del informe, que es la realización de forecasting.

En resumen, mientras que el modelo SARIMA(4,0,1)(1,1,1)[60] es más adecuado si se busca un ajuste más general y una representación precisa de la estructura cíclica de la serie, el modelo SARIMA(4,0,1)(1,1,1)[45] es superior en términos de precisión de

pronóstico, lo que lo convierte en la opción preferida para la tarea de forecasting. A continuación, se presentan los resultados correspondientes a cada configuración.




Fig:14 SARIMA(4,0,1)(1,1,1)(45) de la serie con el pronóstico de 30 días.

SARIMAX Results						
=====						
Dep. Variable:	Temperature		No. Observations:	3622		
Model:	SARIMAX(4, 0, 1)x(1, 1, 1, 45)		Log Likelihood	-10048.746		
Date:	Wed, 23 Apr 2025		AIC	20113.492		
Time:	20:01:49		BIC	20162.950		
Sample:	01-01-1981		HQIC	20131.123		
	- 12-01-1990					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	1.4510	0.017	82.962	0.000	1.417	1.485
ar.L2	-0.6022	0.025	-23.878	0.000	-0.652	-0.553
ar.L3	0.0899	0.023	3.832	0.000	0.044	0.136
ar.L4	0.0559	0.015	3.702	0.000	0.026	0.085
ma.L1	-0.8916	0.012	-74.739	0.000	-0.915	-0.868
ar.S.L45	0.0291	0.016	1.765	0.078	-0.003	0.061
ma.S.L45	-0.9988	0.156	-6.411	0.000	-1.304	-0.693
sigma2	15.2954	2.335	6.549	0.000	10.718	19.873
=====						
Ljung-Box (L1) (Q):	0.01	Jarque-Bera (JB):	364.81			
Prob(Q):	0.92	Prob(JB):	0.00			
Heteroskedasticity (H):	0.82	Skew:	0.43			
Prob(H) (two-sided):	0.00	Kurtosis:	4.31			
=====						

Fig:15 Summary del modelo SARIMA(4,0,1)(1,1,1)(45).

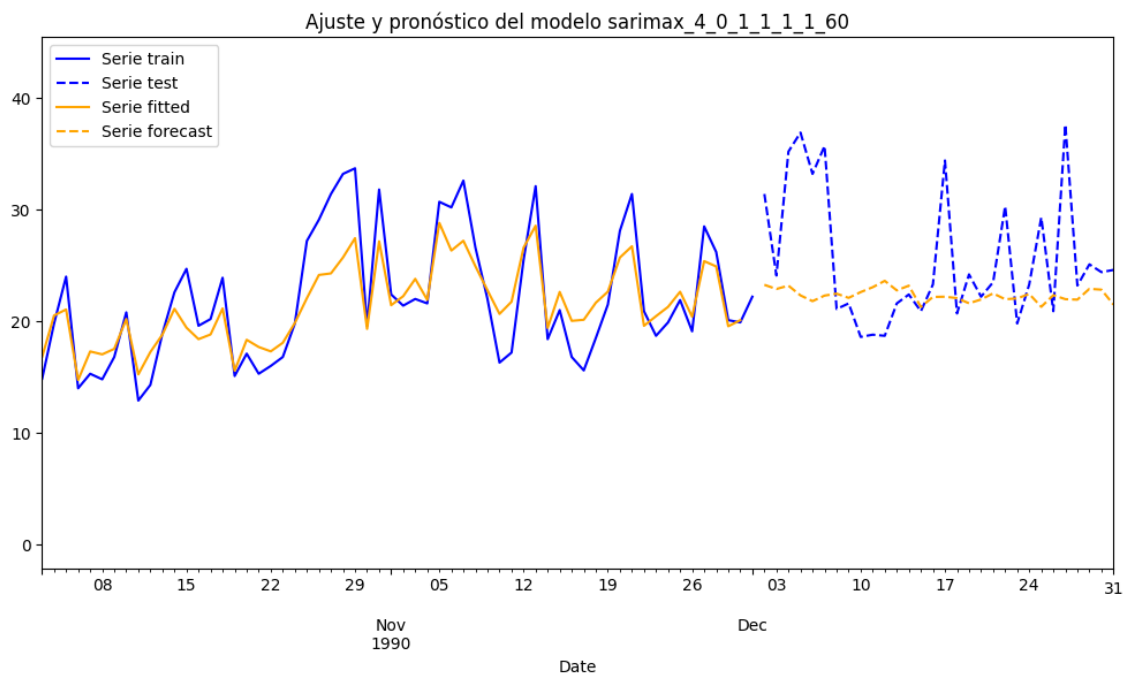


Fig:16 SARIMA(4,0,1)(1,1,1)(60) de la serie con el pronóstico de 30 días.

SARIMAX Results						
=====						
Dep. Variable:	Temperature		No. Observations:		3622	
Model:	SARIMAX(4, 0, 1)x(1, 1, 1, 60)		Log Likelihood		-10025.956	
Date:	Wed, 23 Apr 2025		AIC		20067.912	
Time:	20:20:01		BIC		20117.336	
Sample:	01-01-1981		HQIC		20085.535	
	- 12-01-1990					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	1.4565	0.018	82.335	0.000	1.422	1.491
ar.L2	-0.6095	0.025	-23.914	0.000	-0.659	-0.560
ar.L3	0.0900	0.024	3.783	0.000	0.043	0.137
ar.L4	0.0578	0.015	3.797	0.000	0.028	0.088
ma.L1	-0.8898	0.012	-75.230	0.000	-0.913	-0.867
ar.S.L60	-0.0209	0.017	-1.233	0.217	-0.054	0.012
ma.S.L60	-0.9980	0.139	-7.193	0.000	-1.270	-0.726
sigma2	15.2385	2.040	7.468	0.000	11.239	19.238
=====						
Ljung-Box (L1) (Q):	0.01	Jarque-Bera (JB):	334.04			
Prob(Q):	0.94	Prob(JB):	0.00			
Heteroskedasticity (H):	0.83	Skew:	0.42			
Prob(H) (two-sided):	0.00	Kurtosis:	4.25			
=====						

Fig:17 Summary del modelo SARIMA(4,0,1)(1,1,1)(60).

Modelo	MAE	MSE	RMSE	AIC
sarimax_4_0_1_1_1_1_45	4.728953	44.509959	6.671578	20113.491596
sarimax_4_0_1_1_1_1_30	4.664762	44.636253	6.681037	20130.978832
arima_4_0_2	4.637731	44.650831	6.682128	20177.365070
sarimax_4_0_1_1_1_1_7	4.639112	44.715874	6.686993	20175.635844
arima_4_0_4	4.649368	44.737235	6.688590	20169.256536
sarimax_4_0_1_1_1_1_15	4.667874	44.843014	6.696493	20157.747900
arima_9_0_1	4.665373	45.056665	6.712426	20172.949239
arima_4_0_1	4.665003	45.094895	6.715273	20168.342272
arima_3_0_1	4.672088	45.174594	6.721205	20176.873892
arima_5_0_1	4.672715	45.199095	6.723027	20167.102862
arima_6_0_1	4.676129	45.242637	6.726265	20169.003774
sarimax_4_0_1_1_1_1_60	4.709222	45.335294	6.733149	20067.911720
DES trend add	4.683962	45.740642	6.763183	0
TES trend add seasonal add	5.197241	48.068017	6.933110	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0
arima_10_0_0	4.902778	49.214503	7.015305	20231.295250
arima_9_0_0	4.902873	49.280944	7.020039	20247.687644
arima_8_0_0	4.917738	49.596678	7.042491	20256.629719
TES trend mul seasonal mul	5.177283	49.981925	7.069790	0
arima_5_0_0	5.205321	54.500028	7.382413	20412.400308
arima_2_0_0	5.673183	61.302760	7.829608	20684.713307
arima_1_0_0	5.679291	61.434793	7.838035	20688.210566

5.4 RNN-LSTM

Después de explorar los modelos ARIMA y SARIMA, se probó un modelo LSTM (Long Short-Term Memory) con el objetivo de capturar patrones complejos y no lineales en la

serie de temperatura. Este tipo de red neuronal recurrente permite modelar relaciones de largo plazo sin requerir suposiciones explícitas sobre estacionalidad o linealidad.

El modelo se construyó con una capa LSTM de 100 neuronas y función de activación *ReLU*, seguida por una capa densa completamente conectada. Se utilizó una ventana deslizante de 15 pasos para generar las secuencias de entrada (tamaño definido por el parámetro *n_input*), con una única variable por paso (*n_features* = 1). El entrenamiento se realizó durante 50 épocas con función de pérdida *mean squared error* y optimizador *Adam*.

Si bien el modelo logró un ajuste muy bien y mostró capacidad para seguir la tendencia general de la serie, no logró capturar adecuadamente las oscilaciones diarias en el pronóstico. Se considera que, con un ajuste más exhaustivo de los hiperparámetros y una exploración más amplia de la arquitectura de la red, sería posible mejorar su desempeño y lograr una representación más precisa de las fluctuaciones observadas en los datos.

Dicho esto, también es importante resaltar que, al evaluar el error RMSE sobre el conjunto de test, el modelo LSTM obtuvo la mejor performance de todos los modelos analizados, lo que justifica su consideración como una alternativa competitiva para el pronóstico.

A continuación, se presentan los resultados obtenidos con la configuración actual del modelo LSTM.




Fig:18 LSTM con el pronóstico de 30 días.

Modelo	MAE	MSE	RMSE	AIC
LSTM	4.888561	41.231164	6.421150	0
sarimax_4_0_1_1_1_45	4.728953	44.509959	6.671578	20113.491596
sarimax_4_0_1_1_1_30	4.664762	44.636253	6.681037	20130.978832
arima_4_0_2	4.637731	44.650831	6.682128	20177.365070
sarimax_4_0_1_1_1_7	4.639112	44.715874	6.686993	20175.635844
arima_4_0_4	4.649368	44.737235	6.688590	20169.256536
sarimax_4_0_1_1_1_15	4.667874	44.843014	6.696493	20157.747900
arima_9_0_1	4.665373	45.056665	6.712426	20172.949239
arima_4_0_1	4.665003	45.094895	6.715273	20168.342272
arima_3_0_1	4.672088	45.174594	6.721205	20176.873892
arima_5_0_1	4.672715	45.199095	6.723027	20167.102862
arima_6_0_1	4.676129	45.242637	6.726265	20169.003774
sarimax_4_0_1_1_1_60	4.709222	45.335294	6.733149	20067.911720
DES trend add	4.683962	45.740642	6.763183	0
TES trend add seasonal add	5.197241	48.068017	6.933110	0
SES	4.804388	48.485323	6.963140	0
DES trend mul	4.891813	49.127413	7.009095	0
arima_10_0_0	4.902778	49.214503	7.015305	20231.295250
arima_9_0_0	4.902873	49.280944	7.020039	20247.687644
arima_8_0_0	4.917738	49.596678	7.042491	20256.629719
TES trend mul seasonal mul	5.177283	49.981925	7.069790	0
arima_5_0_0	5.205321	54.500028	7.382413	20412.400308
arima_2_0_0	5.673183	61.302760	7.829608	20684.713307
arima_1_0_0	5.679291	61.434793	7.838035	20688.210566

6. Conclusiones

El análisis realizado sobre las temperaturas máximas diarias de la ciudad de Melbourne ha permitido evaluar diversas técnicas de modelado de series temporales para predecir

el comportamiento de esta variable climática. A lo largo de este proceso, se han utilizado modelos clásicos como el suavizado exponencial (SES, DES y Holt-Winters), ARIMA, SARIMA, y un modelo basado en redes neuronales (LSTM), cada uno con sus fortalezas y limitaciones.

Dentro de los modelos con mejor performance, el modelo SARIMA ha demostrado ser adecuado para capturar la estacionalidad y algo de las variaciones periódicas en los datos de temperatura. Su capacidad para incorporar la componente estacional permitió un mejor ajuste y desempeño al capturar las fluctuaciones recurrentes propias de la serie temporal. Aunque algún coeficiente estacional no fue estadísticamente significativo en el mejor de los modelos SARIMA, este presentó el mejor desempeño en términos de los criterios de ajuste, como el AIC.

Por otro lado, el modelo LSTM mostró un buen desempeño en términos de RMSE y logró capturar la tendencia general de la serie. Sin embargo, no logró reflejar fielmente las oscilaciones diarias, lo que sugiere que una mayor optimización de los hiperparámetros y una exploración más profunda de la arquitectura de la red podrían mejorar su capacidad para capturarlas y hacerlo aún más competitivo.